



La Refinería de Datos



Por qué el preprocesamiento es el paso más crítico en Machine Learning (y cómo dominarlo con scikit-learn).


El Ciclo de Vida de los Datos



Todo Algoritmo Habla un Solo Idioma: Tensores Numéricos

El Caos

Southampton	male	0.42	512.32
Cherbourg	female	0.81	NaN
Queenstown	male	0.12	128.65



El Filtro



Procesamiento y Transformación



La Matriz

0.750	0.000	1.000	0.420	0.999	0.000
0.250	1.000	0.000	0.810	0.000	0.000
0.500	0.000	1.000	0.120	0.250	0.000

Los algoritmos matemáticos no entienden conceptos como Hombre o Cherbourg. Nuestro objetivo en la refinería es traducir la realidad a una representación matricial perfecta.

Los 4 Pilares del Preprocesamiento



1. Limpieza (Cleaning)

Manejo de valores faltantes (NaN) y detección de valores atípicos.



2. Codificación (Encoding)

Traducción de texto y categorías a números.



3. Escalamiento (Scaling)


Normalización y estandarización de rangos numéricos.




4. Ingeniería (Engineering)

Creación, discretización y selección de las mejores características.

Llenando los Vacíos: Imputación de Datos




Rápido, pero ignora el contexto.



Imputación contextual basada en similitud.

Aislando las Anomalías

Valores Atípicos -> IsolationForest



Las anomalías (ej. un billete de Titanic de \$512 cuando la media es \$32) arruinan los modelos. IsolationForest las detecta identificando qué puntos requieren menos cortes matemáticos para ser aislados del grupo principal.

Traducción Categórica: Evitando Jerarquías Falsas

Datos Originales: Puerto

[Cherbourg, Queenstown, Southampton]

Opción A: OrdinalEncoder

[0, 1, 2]



El algoritmo asumirá matemáticamente que **Southampton (2)** es el doble que **Queenstown (1)**. ¡Peligro para modelos lineales!

Opción B: OneHotEncoder

[1, 0, 0]


[0, 1, 0]

[0, 0, 1]




Crea una **matriz dispersa** (sparse matrix). Trata todas las categorías con igual peso. Ideal para variables sin orden jerárquico.

Nivelando el Terreno de Juego





Peso Excesivo: "Tarifa" domina,
haciendo "Edad" irrelevante.



Función Objetivo Distorsionada:
El descenso de gradiente es lento y errático.

Si no escalamos, las características con números grandes dominarán completamente la función objetivo del algoritmo, haciendo invisibles a las características pequeñas.

La Matriz de Escaladores (scikit-learn)

StandardScaler	MinMaxScaler	RobustScaler
		
Media = 0, Varianza = 1	Rango estricto [0, 1]	Usa Mediana e IQR
El estándar por defecto. Asume distribución normal.	Para redes neuronales o cuando las características tienen límites duros (ej. imágenes de píxeles).	Cuando el dataset está infestado de valores atípicos que arruinarían la media matemática.

Moldeando la Distribución Numérica

Transformación No Lineal (QuantileTransformer)



Discretización (KBinsDiscretizer)




Convierte variables continuas en categorías para introducir no-linealidad.

Separando la Señal del Ruido



Más datos no siempre es mejor. Alimentar un modelo con variables irrelevantes introduce ruido, aumenta el sobreajuste (overfitting) y ralentiza el entrenamiento.


La Línea de Ensamblaje: scikit-learn Pipelines



En lugar de ejecutar pasos sueltos, construimos un Pipeline. Esto unifica todo el proceso en una sola entidad automatizada.


Previniendo la Fuga de Datos (Data Leakage)

Pilar 6: Prevención





¡NUNCA uses `fit()` en tus datos de prueba! Si calculas la media o el escalado usando el dataset completo antes de dividirlo, la información del futuro se filtra en tu modelo. El `Pipeline` automatiza esta protección.

Del Caos a la Predicción



Realidad Desordenada



Tensor Listo para ML

El preprocesamiento no es una tarea tediosa antes del trabajo real. Es el trabajo real.
Es el arte de esculpir la realidad en el único formato que las máquinas pueden entender.